

Multi-branch CNN based with multi-head attention multi-class brain disease classification using MPCA reduced dimensionality MRI scans over orthogonal planes

Берлет Максим Валерьевич berletmaximq@gmail.com

Филатов Антон Юрьевич ant.filatov@gmail.com

Аннотация

Своевременная диагностика заболеваний, которые определяются по данным магнитно-резонансной томографии (МРТ), имеет решающее значение для выбора оптимальной тактики лечения. Автоматизация данного процесса обусловлена необходимостью снижения нагрузки на специалистов. Целью данной работы является разработка алгоритма классификации пациентов по МРТ-изображениям, эффективного в условиях ограниченных вычислительных ресурсов и малого объёма размеченных данных. Предложен подход, основанный на декомпозиции трёхмерного МРТ-тензора по ортогональным плоскостям (Multilinear Principal Component Analysis), извлечении признаков с помощью многоветвистой сверточной нейросети и последующем позднем слиянии (late fusion) признаков с применением механизма многоголового внимания (multi-head attention) для адаптивного взвешивания информационных потоков. Оценка проводилась на выборке из 358 снимков пациентов методом 5-кратной кросс-валидации. В качестве метрик использованы точность (Accuracy) и Macro F1-мера. На Hold-out валидации модель продемонстрировала $Accuracy = 0.9444$ и $F1 = 0.9592$.

Ключевые слова — Multilinear Principal Component Analysis; Многоветвистая сверточная нейросеть; Многоголовое внимание; Позднее слияние признаков; Классификация; МРТ;

1 Введение

Нейродегенеративные заболевания представляют собой группу прогрессирующих патологий центральной нервной системы, характеризующихся постепенной гибелью нейронов и нарушением функций головного мозга. К таким заболеваниям относятся болезнь Альцгеймера, болезнь Паркинсона, рассеянный склероз и другие. В связи с глобальным старением населения их распространённость неуклонно растёт, что делает раннюю диагностику одной из наиболее актуальных задач современной медицины.

Магнитно-резонансная томография (МРТ) является методом неинвазивной диагностики данных патологий. Однако интерпретация МРТ-исследований требует высокой квалификации и значительных временных затрат, что приводит к дефициту кадров и задержкам в постановке диагноза.

В последние годы активно развиваются методы автоматического анализа медицинских изображений на осно-

ве глубокого обучения. Большинство современных подходов демонстрируют высокую точность при использовании больших размеченных датасетов и мощных графических ускорителей. Тем не менее, в реальной клинической практике часто встречаются ограничения по вычислительным ресурсам.

Существующие методы можно разделить на две основные группы. К первой относятся подходы, работающие напрямую с трёхмерными данными (3D-CNN, Transformer-based модели). Они обычно показывают наилучшее качество, но требуют значительных вычислительных ресурсов. Ко второй группе относятся методы, основанные на обработке отдельных срезов (2D-CNN). Такие подходы менее ресурсоемкие, однако требуют изначальной разметки специалистом конкретных срезов из сырых МРТ-тензоров, причем часто в работах никак не оговаривается алгоритм выбора конкретных срезов снимка.

В связи с этим остаётся актуальной задача разработки моделей классификации МРТ-изображений, которые полностью автоматизированы (начиная с прозрачности этапа выбора срезов), а также не требуют значительных вычислительных ресурсов.

Целью настоящей работы является разработка прозрачного метода классификации пациентов по МРТ-изображениям головного мозга в условиях ограниченных вычислительных ресурсов и малого размера размеченной выборки.

Для достижения цели предлагается комбинированный подход, включающий:

- Снижение размерности трёхмерного МРТ-тензора по ортогональным плоскостям с использованием Multilinear Principal Component Analysis (MPCA);
- Извлечение признаков (feature extraction) с помощью многоветвистой (3 ветви, по одной для каждой МРТ плоскости) сверточной нейронной сети;
- Позднее слияние признаков (late fusion) с применением механизма многоголового внимания (multi-head attention) для адаптивного взвешивания вкладов различных проекций.

Основной вклад работы заключается в разработке подхода, демонстрирующего высокую обобщающую способность в условиях ограниченного объёма размеченных данных.

2 Аналитический обзор

В работе [1] представлена легковесная двухпутевая сверточная нейросеть для мультиклассовой классификации опухолей головного мозга по предобработанным аксиальным срезам МРТ. Архитектура сети включает две параллельные ветви с различными размерами сверточных ядер: меньшее ядро ориентировано на извлечение локальных текстурных признаков, в то время как крупное ядро улавливает глобальный пространственный контекст. Извлеченные карты признаков конкатенируются и преобразуются в одномерный вектор. Ключевой особенностью подхода является интеграция модуля трехэтапного статистического отбора, который изолирует K наиболее информативных признаков, существенно снижая размерность входного пространства последующего полносвязного слоя. К достоинствам метода относится высокая обобщающая способность (0.96 Ассигасу) при небольших вычислительных затратах (модель имеет 861 545 параметров). Однако существенным ограничением работы является использование МРТ-данных из сомнительного источника: авторы приводят ссылку на датасет из каггла, в свою очередь датасет из каггла ссылается на другой датасет из каггла, а автор исходного датасета в качестве источника данных указывает поиск в гугл картинках. Нет никакой гарантии отсутствия утечки данных (data leakage). Ко всему прочему, датасет исходный датасет состоит уже из картинок (конкретных срезов МРТ-тензора), каким образом выбирались срезы нигде не указывается.

Метод [2] основан на выделении признаков из области интереса (ROI), включающих геометрические, статистические и пространственно-текстурные характеристики. С целью снижения размерности пространства признаков авторы применили метод отбора на основе корреляционного анализа (correlation feature selection), что позволило сократить вектор признаков до 11 наиболее информативных компонентов. Сформированные векторы подавались на вход различных классификаторов, включая классический многослойный перцептрон (MLP), рекуррентную нейронную сеть (RNN) и ансамблевые методы машинного обучения. Ключевым достоинством данной работы является успешное решение задачи многоклассовой классификации (дифференциация 6 типов новообразований, тогда как большинство существующих исследований сфокусированы на бинарной задаче), а также достижение высокой точности (Ассигасу до 0.986) при использовании алгоритма Random Committee. Однако существенным недостатком предложенного пайплайна является его строгая зависимость от качества предварительной бинарной сегментации (алгоритма ER-BHS): любая ошибка на этапе выделения контуров ROI приводит к искажению вычисляемых признаков. На этапе предобработки выбирались конкретные срезы МРТ-тензора, однако никакого описания, по какому принципу происходил отбор, нет.

Использование трансформеров для анализа медицинских изображений рассматривается в работе [4], где авторы модифицировали архитектуру ViT (модель FTVT-116), адаптировав её под мультиклассовую классификацию МРТ-сканов с ассигасу до 0.987. Однако, несмотря на высокие метрики, предложенное решение обладает рядом огра-

ничений. Во-первых, $\frac{2}{3}$ данных имеют сомнительное происхождение: в работе было использовано 3 датасета, figshare - открытый датасет с известным происхождением, а оставшиеся два датасета: датасет из первой статьи, который набран из гугл картинок и датасет Br35H, который был выложен на каггл, о происхождении которого ничего неизвестно. Во-вторых, архитектура ViT остается требовательной к вычислительной инфраструктуре: для её обучения авторам потребовалось привлечение аппаратных ресурсов платформы Kaggle (две GPU NVIDIA T4). В-третьих, использованные датасеты, несмотря на их качество, состоят уже из конкретных срезов (mri slices) МРТ и нет никакой информации, каким образом отбирались срезы.

В работе [5] авторы предложили многоветвистую архитектуру на основе блоков Inception для мультиклассовой классификации МРТ-изображений головного мозга. Благодаря параллельным ветвям с различными размерами ядер свертки (1×1 , 3×3 , 5×5), модель эффективно адаптируется к мультимасштабным признакам новообразований, демонстрируя высокую точность (Ассигасу до 0.993) при пятикратной кросс-валидации. Тем не менее, подход имеет ряд ограничений: авторы используют данные сомнительного качества, автор датасета Br35H не указывает первоисточник снимков. Также используемые данные являются отдельными срезами МРТ, однако нет никакой информации, по какому принципу были отобраны конкретные срезы.

В работе [8] авторы предложили классическую Feed-Forward сверточную нейронную сеть (MCCNN) для решения задачи многоклассовой классификации опухолей головного мозга. Предложенная архитектура продемонстрировала высокую точность (Ассигасу) как на предобработанных данных после удаления черепа (до 0.99), так и на «сырых» снимках, содержащих костные структуры (до 0.96). Существенным преимуществом данного подхода является высокая параметрическая эффективность модели (модель содержит 13 млн. параметров), что снижает требования к вычислительным ресурсам. Однако ключевым ограничением работы остается отсутствие прозрачности, каким именно образом авторы выбирают конкретные срезы МРТ снимка.

Несмотря на значительный прогресс в решении задачи классификации по МРТ, существующие решения либо требуют больших вычислительных ресурсов и объемов данных, либо используют данные сомнительного качества, либо допускают методологические ошибки, не указывая, каким образом выбираются конкретные срезы МРТ. В отличие от них, предлагаемый в данной работе подход не требует значительных вычислительных ресурсов и больших объемов данных за счет использования предобученных моделей, притом имеет максимально прозрачную методологию эксперимента.

3 Метод

3.1 Описание набора данных

Объем общедоступных данных магнитно-резонансной томографии (МРТ) в формате .nii (представленных в виде трехмерных тензоров) является крайне ограниченным. До-

полнительную сложность представляет мультиклассовый характер решаемой задачи. В связи с этим был сформирован агрегированный набор данных **из открытых репозиториях, включающий**: 96 снимков пациентов с синдромом дефицита внимания и гиперактивности (СДВГ) [13], 79 снимков пациентов с расстройством аутистического спектра (РАС) [3], 44 снимка пациентов с болезнью Альцгеймера [9], 40 снимков пациентов с болезнью Паркинсона [10], 82 снимков контрольной группы [7] [3] [13], а также 17 снимков пациентов с рассеянным склерозом, выделенных в качестве дополнительного тестового подмножества [12].

В связи с гетерогенной природой нейропсихиатрических заболеваний, сбор данных для класса расстройства аутистического спектра (РАС) сопряжен с рядом методологических трудностей. Предварительный разведочный анализ (exploratory data analysis) показал, что часть снимков РАС обладает высокой вариабельностью протоколов сканирования и потенциальным шумом в разметке, что приводило к размыванию границы принятия решений между РАС и контрольной группой на этапе обучения. Тем не менее, для сохранения клинической репрезентативности и оценки способности модели к тонкой дифференциальной диагностике, класс РАС был сохранен в итоговом наборе данных, состоящем из **358** снимков и 6 классов.

Набор данных содержит снимки как в T1-, так и в T2-взвешенных последовательностях. Значительная часть данных была получена в исходном (сыром) виде, тогда как остальные снимки уже прошли первичную предобработку (удаление черепной коробки, сегментация серого вещества, пространственное сглаживание и регистрация в единое координатное пространство).

3.2 Предобработка данных

После агрегации все исходные снимки прошли двухэтапную процедуру предобработки.

На первом этапе применялся стандартизированный конвейер обработки с использованием программного обеспечения FSL (FMRIB Software Library):

- Удаление черепной коробки (skull stripping) с помощью утилиты `fsl bet`.
- Сегментация и выделение серого вещества с использованием `fsl fast`.
- Пространственная регистрация МРТ-снимков в стандартное пространство MNI152 с применением `fsl flirt`.
- Пространственное сглаживание изображений с использованием `fsl math`.

На втором этапе к агрегированному набору данных был применен модифицированный итеративный алгоритм снижения размерности тензорных данных — многомерный анализ главных компонент (МРСА, Multilinear Principal Component Analysis).

3.3 Обоснование и применение алгоритма МРСА

Алгоритм МРСА [6] является многомерным обобщением классического метода главных компонент (РСА). Его ключевым преимуществом является возможность непосредственной работы с тензорами произвольной размерности без их предварительного развертывания в векторы. В контексте данной работы рассматриваются тензоры строго определенной размерности, что позволяет формализовать задачу с учетом специфики предметной области.

Формализация задачи:

- **Вход:** $\mathcal{X} \in \mathbb{R}^{N \times I_1 \times I_2 \times I_3}$ — исходный набор данных после первого этапа предобработки, где N — количество образцов, а I_1, I_2, I_3 — пространственные размерности тензора.
- **Выход:** $\mathcal{Y} \in \mathbb{R}^{N \times I_1 \times I_2 \times 3}$ — преобразованный набор данных после применения МРСА.

При этом преобразование описывается как $\mathcal{Y} = \mathcal{X} \times_4 U^{(4)T}$, где $U^{(4)T} \in \mathbb{R}^{3 \times I_3}$, а матрица $U^{(4)}$ находится путем решения задачи оптимизации:

$$\arg \max_{U^{(4)}} \sum_{k=1}^N \|Y_k - \bar{Y}\|_F^2. \quad (1)$$

Выбор размерности $\mathcal{Y} \in \mathbb{R}^{N \times I_1 \times I_2 \times 3}$ выходного тензора обосновывается необходимостью применения методов трансферного обучения (transfer learning). В условиях ограниченного объема данных обучение глубокой нейронной сети с нуля сопряжено с высоким риском переобучения. Оптимальным решением является использование предобученных сверточных нейронных сетей (CNN), извлекающих общие признаки из крупномасштабных наборов данных, таких как ImageNet. Поскольку изображения в ImageNet представлены в формате RGB (3 канала), целевая размерность данных также должна быть приведена к 3 каналам.


С учетом анатомической специфики МРТ-снимков, имеющих три ортогональные плоскости (сагитальную, фронтальную и аксиальную), применение алгоритма МРСА позволяет сгенерировать следующие представления:

$$\begin{aligned} \mathcal{L}_{\text{sagittal}} &\in \mathbb{R}^{N \times I_1 \times I_2 \times 3}, \\ \mathcal{L}_{\text{frontal}} &\in \mathbb{R}^{N \times I_1 \times 3 \times I_3}, \\ \mathcal{L}_{\text{axial}} &\in \mathbb{R}^{N \times 3 \times I_2 \times I_3}. \end{aligned}$$


Таким образом, на входе алгоритма имеется N трехмерных МРТ-снимков размерности $I_1 \times I_2 \times I_3$, а на выходе формируется $3N$ двумерных изображений размерности $J_1 \times J_2 \times 3$ (по N срезов для каждой из трех плоскостей), пригодных для обработки стандартными CNN-архитектурами.

На картинках 1 можно оценить результат работы алгоритма МРСА - проекции вдоль соответствующих ортогональных осей.


Анализ устойчивости на новых данных. Ранее было сказано, что отдельно было найдено 17 дополнительных снимков пациентов с рассеянным склерозом с целью пробы применения заранее обученных матриц проекций к новым данным.



(а) Аксиальная



(б) Фронтальная



(с) Сагиттальная

Рис. 1: Пример работы алгоритма МРСА

3.4 Архитектура модели

На рисунке 2 представлено схематическое описание архитектуры.

Архитектура предлагаемой модели построена на следующих принципах. На вход нейронной сети подаются три изображения, соответствующие различным анатомическим плоскостям одного и того же магнитно-резонансного томографического (МРТ) исследования. Извлечение признаков осуществляется с помощью трех независимых потоков (branches), реализованных на базе архитектуры ConvNeXt-Tiny. Каждый поток обрабатывает данные соответствующей плоскости, формируя на выходе плотный вектор признаков (dense feature vector), характеризующий данную проекцию. Для слияния информации между различными плоскостями применяется механизм множественного внимания (Multi-Head Attention). В рамках данного модуля в качестве запроса (Query, Q) выступает вектор признаков конкретной плоскости, тогда как в роли ключей (Key, K) и значений (Value, V) используется конкатенация векторов признаков всех трех плоскостей. После проецирования исходных представлений в пространство внимания выполняется операция глобального усреднения (mean pooling). Результирующий агрегированный вектор признаков затем подается на вход блока классификации (classification head) для формирования итогового прогноза.

3.5 Алгоритм обучения

На этапе обучения данные были разбиты на 2 подвыборки: обучающая и тестовая в соотношении 0.8 и 0.2 соответственно. К обучающим данным на этапе обучения применялись техники аугментации из таблицы 1.

В качестве функции потерь выбрана взвешенная кросс-энтропия, в качестве оптимизатора выбран AdamW (см. параметры в таблице 2).

4 Эксперименты и результаты

4.1 Подбор гиперпараметров

В связи с малым объемом выборки и высоким риском переобучения для подбора гиперпараметров использовался метод nested 3-fold stratified cross-validation.

В качестве целевой метрики для подбора гиперпараметров и итоговой оценки модели был выбран **Macro F1-score**. Выбор данной метрики обусловлен выраженным дисбалансом классов в агрегированном наборе данных (например, соотношение классов СДВГ и рассеянного склероза составляет 96:17).

Таблица 1: Применяемые техники аугментации данных

Метод и параметры
RandomAffine degrees=(-7, 7), translate=(0.08, 0.08), scale=(0.92, 1.10), shear=(-7, 7), interpolation=BICUBIC, fill=0
ElasticTransform alpha=120, sigma=8, interpolation=BICUBIC, fill=0
RandomHorizontalFlip p=0.5
RandomVerticalFlip p=0.15
ColorJitter brightness=(0.7, 1.4), contrast=(0.75, 1.35), saturation=0, hue=0
GaussianNoise sigma=0.015
GaussianBlur kernel_size=3, sigma=(0.4, 1.4)

Таблица 2: Параметры оптимизатора AdamW

Оптимизатор и параметры
AdamW weight_decay=1e-4
Группы параметров:
clf_head lr=3e-4
model_ax lr=1e-6, requires_grad=True
model_sag lr=1e-6, requires_grad=True
model_front lr=1e-6, requires_grad=True




Рис. 2: Архитектура модели

Использование метрик *Micro F1* или *Weighted F1* в условиях столь значительного дисбаланса привело бы к доминированию мажоритарных классов в итоговой оценке: модель могла бы демонстрировать высокие агрегированные показатели за счет корректной классификации частых заболеваний, игнорируя при этом паттерны редких патологий. В клинической практике ложноотрицательный результат для любого из рассматриваемых заболеваний несет одинаково высокие риски для пациента. Метрика Macro F1, вычисляющая среднее значение F1-меры по всем классам без учета их размера, обеспечивает равнозначный вклад каждого заболевания в итоговую оценку и принуждает алгоритм к формированию разделяющих границ для всех классов, включая миноритарные.

Поиск гиперпараметров (Inner Loop). Оптимизация гиперпараметров архитектуры (базовая модель ConvNeXt, размерность скрытого слоя, количество голов внимания, скорость обучения) осуществлялась с использованием байесовской оптимизации (алгоритм TPE, фреймворк Optuna). Для оценки каждой комбинации гиперпараметров применялась 3-кратная стратифицированная кросс-валидация на обучающем подмножестве. В качестве целевой метрики оптимизации выступал Macro F1-score, усредненный по фолдам. Использование стратификации гарантировало сохранение пропорций классов в каждом фолде, что критически важно в условиях выраженного дисбаланса выборки.

Финальная оценка (Outer Loop). После определения оптимального набора гиперпараметров, финальная модель обучалась на объединенном обучающем и валидационном подмножествах (0.8 данных) и оценивалась на полностью изолированном тестовом подмножестве (0.2 данных), которое не участвовало ни в обучении, ни в процессе подбора гиперпараметров. Данный подход исключает утечку

данных (data leakage) и обеспечивает несмещенную оценку обобщающей способности алгоритма.

В качестве функции потерь на всех этапах использовался взвешенный FocalLoss (weighted FocalLoss) с коэффициентами, обратными частоте классов, что позволило нивелировать влияние дисбаланса на процесс оптимизации градиентным спуском.

4.2 Основные результаты классификации

Метрика	Значение
Weighted FocalLoss	0.0012
Accuracy	0.9444
Macro F1	0.9592
Macro Recall	0.9607
Macro Precision	0.9666

Таблица 3: Результаты классификации на тестовой выборке (hold-out validation)

Анализ матрицы ошибок обученной модели демонстрирует, что алгоритм допускает ошибки классификации исключительно при сопоставлении пациентов с РАС и представителей контрольной группы, в то время как остальные классы разделяются с высокой точностью. Данное эмпирическое наблюдение находится в полном согласии с фундаментальными проблемами нейровизуализационной диагностики РАС. В отличие от заболеваний с выраженными макроскопическими структурными изменениями, нейроанатомические и функциональные маркеры РАС носят распределенный характер. Как отмечается в недавнем систематическом обзоре и метаанализе ([11]), ключевым пре-

Таблица 4: Результаты абляционного исследования

Вариант архитектуры	Accuracy	Macro Recall	Macro Precision	Macro F1
Single Branch (Эвристический срез)	0.8318 ± 0.0285	0.8365 ± 0.0225	0.8440 ± 0.0327	0.8157 ± 0.0296
Single Branch (MPCA)	0.8656 ± 0.0359	0.8714 ± 0.0272	0.8702 ± 0.0413	0.8437 ± 0.0342
Multi Branch (MPCA + Mean)	0.9108 ± 0.0269	0.9127 ± 0.0271	0.9280 ± 0.0245	0.8939 ± 0.0255
Multi Branch (MPCA + Cat)	0.9206 ± 0.0115	0.9203 ± 0.0122	0.9313 ± 0.0167	0.8995 ± 0.0162
Multi Branch (MPCA + MHA + Mean)	0.9053 ± 0.0279	0.9056 ± 0.0292	0.9170 ± 0.0315	0.8883 ± 0.0293
Multi Branch (MPCA + MHA + Cat)	0.9223 ± 0.0089	0.9226 ± 0.0090	0.9359 ± 0.0135	0.9022 ± 0.0125

пятствием для бинарной классификации РАС и здоровых лиц является выраженная биологическая гетерогенность расстройства. Эта гетерогенность приводит к тому, что в пространстве признаков кластеры РАС и контрольной группы неизбежно пересекаются: часть индивидов с РАС демонстрирует нейровизуализационные паттерны, статистически неотличимые от нормы, что и обуславливает наблюдаемые ошибки классификации исключительно между этими двумя классами. Таким образом, зона неопределенности между группами отражает не недостаток предложенного алгоритма, а объективную биологическую вариативность внутри спектра аутизма

зового уровня (baseline) была разработана и протестирована эвристическая модель отбора наиболее информативных срезов (Top-3 Informative Slices).

В отличие от тривиального подхода, при котором единственный центральный срез дублируется во все три канала (R=G=B), что приводит к нулевой межканальной дисперсии и вырождению первого сверточного слоя, предложенный базовый уровень формирует псевдо-RGB представление путем выбора трёх различных срезов по ортогональной плоскости. Критерием отбора выступала норма Фробениуса ковариационной матрицы центрированного среза:

$$\text{Score}(S_i) = \|C_i\|_F, \quad C_i = \frac{1}{W-1} \tilde{S}_i \tilde{S}_i^T, \quad (2)$$

где $\tilde{S}_i$ — матрица среза с вычтенным средним значением. Данный критерий отбирает не просто срезы с максимальной интенсивностью сигнала, а срезы с наибольшей текстурной сложностью и структурной вариативностью, что максимизирует информационную емкость входного тензора для предобученной 2D-сети.

Сравнение результатов представлено в таблице 4. Переход от эвристического отбора локальных срезов (Top-3 Informative Slices) к глобальной тензорной проекции (MPCA) обеспечил прирост Macro F1 на $\sim 2.8\%$.

Последовательное усложнение архитектуры агрегации признаков позволило выявить оптимальную конфигурацию многоветвистой модели. Как следует из таблицы 4, простое усреднение выходов механизма внимания (MPCA + MHA + Mean) оказывается неэффективным: несмотря на использование адаптивного механизма взвешивания, итоговая производительность модели уступает базовому варианту с конкатенацией (MPCA + Cat), а дисперсия метрик возрастает почти вдвое, что свидетельствует о повышенной чувствительности архитектуры к разбиению на фолды. Преодолеть данное ограничение удалось за счёт отказа от усреднения в пользу конкатенации признаков, обработанных механизмом MHA. Итоговая конфигурация (MPCA + MHA + Cat) не только превосходит все предыдущие варианты по абсолютным значениям метрик, но и демонстрирует минимальный разброс результатов при кросс-валидации, что подтверждает её пригодность для решения задач дифференциальной диагностики, где критически важна воспроизводимость предсказаний.




Рис. 3: Матрица ошибок на тестовой выборке

Способность модели безошибочно выделять сложные патологии (Alzheimer, Parkinson, Sclerosis) и при этом демонстрировать ожидаемую клиническую неопределенность (см. рис. 3) исключительно на границе контрольная группа - РАС, подтверждает, что алгоритм извлекает релевантные биомаркеры, а не опирается на случайные артефакты датасета. Это служит дополнительным свидетельством валидности предложенного подхода на основе MPCA и Multi-Head Attention.

4.3 Абляционное исследование

Для объективной оценки вклада тензорной декомпозиции MPCA в итоговое качество классификации, в качестве ба-

5 Заключение

В рамках данного исследования был предложен новый подход к решению задачи классификации, основанный на использовании ортогональных плоскостей снимков МРТ, вычисленных с помощью МРСА, многоветвистой сверточной модели с использованием механизма многоголового внимания. Предложенный подход с использованием нескольких плоскостей дал значительное увеличение метрики Мастро F1 с 0.8157 ± 0.0296 в базовом подходе до 0.9022 ± 0.0125 в предложенном [4]. Несмотря на достигнутые результаты, текущий подход имеет ряд ограничений. В частности, эффективность модели снижается при работе с классом РАС, а процесс обучения с ростом выборки требует значительных вычислительных ресурсов для первичной предобработки сырых данных с помощью МРСА.

Список литературы

- [1] Batool Amreen и Byun Yung-Cheol. «A lightweight multi-path convolutional neural network architecture using optimal features selection for multiclass classification of brain tumor using magnetic resonance images». В: *Results in Engineering* 15 (2025).
- [2] Ali Aqib и др. «Multi-class brain tumor MRI segmentation and classification using deep learning and machine learning approaches». В: *Cancer Imaging* 18 (2025).
- [3] *Autism Brain Imaging Data Exchange I ABIDE I*. 2012. URL: https://fcon_1000.projects.nitrc.org/indi/abide/abide_I.html.
- [4] Reddy C. Kishor Kumar и др. «A fine-tuned vision transformer based enhanced multi-class brain tumor classification using MRI scan imagery». В: *Frontiers in Oncology* 23 (2024).
- [5] Rastogi Deependra и др. «Multi-class classification of brain tumour magnetic resonance images using multi-branch network with inception block and five-fold cross validation deep learning framework». В: *Biomedical Signal Processing and Control* 22 (2024).
- [6] Lu Haiping, Plataniotis K.N. и Venetsanopoulos A.N. «MPCA: Multilinear Principal Component Analysis of Tensor Objects». В: *IEEE Transactions on Neural Networks* 43 (2006).
- [7] *Information eXtraction from Images*. URL: <https://brain-development.org/ixi-dataset/>.
- [8] Jaspin K. и Selvan Shirley. «Multiclass convolutional neural network based classification for the diagnosis of brain MRI images». В: *Biomedical Signal Processing and Control* 18 (2023).
- [9] *OASIS-3: Longitudinal Neuroimaging, Clinical, and Cognitive Dataset for Normal Aging and Alzheimer Disease*. 2019. URL: <https://sites.wustl.edu/oasisbrains/home/oasis-3/>.
- [10] *Parkinson's Precision Medicine Initiative*. URL: <https://www.ppmi-info.org/access-data-specimens/download-data>.
- [11] Schielen Sijr J. C. и др. «The diagnosis of ASD with MRI: a systematic review and meta-analysis». В: *Translational Psychiatry* 11 (2024).
- [12] *The 2015 Longitudinal MS Lesion Segmentation Challenge*. 2015. URL: <https://iacl.ece.jhu.edu/index.php/MSChallenge>.
- [13] *The Neuro Bureau ADHD-200 Preprocessed repository*. 2017. URL: <http://preprocessed-connectomes-project.org/adhd200/>.