Оригинальное исследование
№ –: 1–14
УДК: 999.999
http://cte.eltech.ru
doi:10.32603/2071-2340-2026-4-XXX-XXX

MPCA-ATTENTION: МНОГОВЕТВИСТАЯ CNN ДЛЯ КЛАССИФИКАЦИИ МРТ ПОСРЕДСТВОМ ОРТОГОНАЛЬНЫХ ПРОЕКЦИЙ

Берлет М. В.[1] ✉ berletmaximq@gmail.com, https://orcid.org/0009-0003-0513-3806
Филатов А. Ю.[1] aifilatov@etu.ru, https://orcid.org/0000-0003-4298-8523

[1]Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В. И. Ульянова (Ленина), Российская Федерация, 197022, Санкт-Петербург, ул. Профессора Попова, 5

Аннотация

Своевременная диагностика заболеваний, которые определяются по данным магнитно-резонансной томографии (МРТ), имеет решающее значение для выбора оптимальной тактики лечения. Автоматизация данного процесса обусловлена необходимостью снижения нагрузки на специалистов. Целью данной работы является разработка алгоритма классификации пациентов по МРТ-изображениям, эффективного в условиях ограниченных вычислительных ресурсов и малого объёма размеченных данных. Предложен подход, основанный на декомпозиции трёхмерного МРТ-тензора по ортогональным плоскостям(Multilinear Principal Component Analysis), извлечении признаков с помощью многоветвистой сверточной нейросети и последующем позднем слиянии (late fusion) признаков с применением механизма многоголового внимания (multi-head attention) для адаптивного взвешивания информационных потоков. Оценка проводилась на выборке из 358 снимков пациентов методом 5-кратной кросс-валидации. В качестве метрик использованы точность (Accuracy) и Macro F1-мера. На Hold-out валидации модель продемонстрировала Accuracy = 0.9444 и Macro-F1 = 0.9592.

Ключевые слова: *Multilinear Principal Component Analysis; Многоветвистая сверточная нейросеть; Многоголовое внимание; Позднее слияние признаков; Классификация; МРТ;*

Цитирование: Берлет М. В., Филатов А. Ю. MPCA-Attention: многоветвистая CNN для классификации МРТ посредством ортогональных проекций // Компьютерные инструменты в образовании. 2026. № –. С. 1–14. doi:10.32603/2071-2340-2026-4-XXX-XXX.

Berlet M. V., Filatov A. Y.
MPCA-Attention: Multi-Branch CNN for MRI Classification via Orthogonal Projections.
© Computer Tools in Education, 2026. No –. P. 1–14.

1. ВВЕДЕНИЕ

Нейродегенеративные заболевания представляют собой группу прогрессирующих патологий центральной нервной системы, характеризующихся постепенной гибелью нейронов и нарушением функций головного мозга. К таким заболеваниям относятся болезнь Альцгеймера, болезнь Паркинсона, рассеянный склероз и другие. В связи с глобальным старением населения их распространённость неуклонно растёт, что делает раннюю диагностику одной из наиболее актуальных задач современной медицины.

Магнитно-резонансная томография (МРТ) является методом неинвазивной диагностики данных патологий. Однако интерпретация МРТ-исследований требует высокой квалификации и значительных временных затрат, что приводит к дефициту кадров и задержкам в постановке диагноза.

В последние годы активно развиваются методы автоматического анализа медицинских изображений на основе глубокого обучения. Большинство современных подходов демонстрируют высокую точность при использовании больших размеченных датасетов и мощных графических ускорителей. Тем не менее, в реальной клинической практике часто встречаются ограничения по вычислительным ресурсам.

Существующие методы можно разделить на две основные группы. К первой относятся подходы, работающие напрямую с трёхмерными данными [1]. Они обычно показывают наилучшее качество, но требуют значительных вычислительных ресурсов. Ко второй группе относятся методы, основанные на обработке отдельных срезов [2]. Такие подходы менее ресурсоемкие, однако требуют изначальной разметки специалистом конкретных срезов из сырых МРТ-тензоров, причем часто в работах никак не оговаривается алгоритм выбора конкретных срезов снимка.

В связи с этим остаётся актуальной задача разработки моделей классификации МРТ-изображений, которые полностью автоматизированы (начиная с прозрачности этапа выбора срезов), а также не требуют значительных вычислительных ресурсов.

Целью настоящей работы является разработка прозрачного метода классификации пациентов по МРТ-изображениям головного мозга в условиях ограниченных вычислительных ресурсов и малого размера размеченной выборки.

Для достижения цели предлагается комбинированный подход, включающий:

- Снижение размерности трёхмерного МРТ-тензора по ортогональным плоскостям с использованием Multilinear Principal Component Analysis (MPCA);
- Извлечение признаков (feature extraction) с помощью многоветвевой (3 ветви, по одной для каждой МРТ плоскости) свёрточной нейронной сети;
- Позднее слияние признаков (late fusion) с применением механизма многоголового внимания (multi-head attention) для адаптивного взвешивания вкладов различных проекций.

Основной вклад работы заключается в разработке подхода, демонстрирующего высокую обобщающую способность в условиях ограниченного объёма размеченных данных.

2. АНАЛИТИЧЕСКИЙ ОБЗОР

В работе [2] представлена легковесная двухпутевая сверточная нейросеть для мультиклассовой классификации опухолей головного мозга. Архитектура сети включает две параллельные ветви с различными размерами сверточных ядер: меньшее ядро ориентировано на извлечение локальных текстурных признаков, в то время как крупное ядро улавливает глобальный пространственный контекст. Ключевой особенностью подхода является интеграция модуля трехэтапного статистического отбора, который изолирует K наиболее информативных признаков, существенно снижая размерность пространства. К достоинствам метода относится высокая обобщающая способность (Accuracy 0.96) при небольших вычислительных затратах (861 545 параметров).

Метод [3] основан на выделении признаков из области интереса (ROI), включающих геометрические, статистические и пространственно-текстурные характеристики. С целью снижения размерности пространства признаков авторы применили метод отбора на основе корреляционного анализа, что позволило сократить вектор признаков до 11 наиболее информативных компонентов, подаваемых на вход классическим классификаторам (MLP, RNN, Random Committee). Ключевым достоинством работы является успешное решение задачи дифференциации 6 типов новообразований с высокой точностью (Accuracy до 0.986). Однако существенным недостатком предложенного пайплайна остается его строгая зависимость от качества предварительной бинарной сегментации (алгоритма ER-BHS): любая ошибка на этапе выделения контуров ROI неизбежно приводит к искажению вычисляемых признаков.

Использование трансформеров для анализа медицинских изображений рассматривается в работе [4], где авторы модифицировали архитектуру ViT (модель FTVT-l16), адаптировав её под мультиклассовую классификацию МРТ-сканов (Accuracy до 0.987). Несмотря на высокие метрики, предложенное решение ограничено высокой требовательностью к вычислительной инфраструктуре: для обучения модели авторам потребовалось привлечение аппаратных ресурсов платформы Kaggle (две GPU NVIDIA T4).

В работе [5] авторы предложили многоветвистую архитектуру на основе блоков Inception. Благодаря параллельным ветвям с различными размерами ядер свертки (1×1, 3×3, 5×5), модель эффективно адаптируется к мультимасштабным признакам новообразований, демонстрируя высокую точность (Accuracy до 0.993) при пятикратной кросс-валидации.

В работе [6] представлена классическая сверточная нейронная сеть (CNN). Предложенная архитектура продемонстрировала высокую точность как на предобработанных данных после удаления черепа (до 0.99), так и на «сырых» снимках, содержащих костные структуры (до 0.96). Существенным преимуществом данного подхода является высокая параметрическая эффективность модели (13 млн параметров), что снижает требования к вычислительным ресурсам.

Несмотря на архитектурное разнообразие рассмотренных подходов [2, 3, 4, 5, 6], большинство из них страдает от системных методологических недостатков, связанных с формированием обучающих выборок. Во-первых, наблюдается использование неясных данных. Работы [2, 4, 5] опираются на наборы данных (такие как агрегаторы Sartajbhuvaji и Br35H), первоисточниками которых в ряде случаев выступают неструктурированные поисковые запросы (Google Images) или непроверенные пользовательские репозитории. Отсутствие верифицированного протокола формирования наборов не позволяет исключить риск неконтролируемой утечки данных (data leakage) и не гарантирует их клиниче-

ской репрезентативности. Во-вторых, во всех рассмотренных исследованиях [2, 3, 4, 5, 6] отсутствует формализованное описание этапа экстракции признаков. Авторы используют либо готовые двумерные проекции из агрегированных наборов [2, 4, 5], либо самостоятельно извлекают отдельные срезы из валидных объемных МРТ-тензоров (например, BraTS 2015 или figshare) [3, 6]. При этом критерии отбора конкретных срезов (например, фиксация координат, наличие опухоли, метод аугментации) нигде не регламентируются. Подобная непрозрачность этапа предобработки снижает воспроизводимость результатов и ставит под сомнение надежность моделей, поскольку принцип выбора информативных 2D-срезов критически важен для качества итоговой диагностики. В отличие от рассмотренных работ, предлагаемый подход не требует значительных вычислительных ресурсов и больших объемов данных засчет использования предобученных моделей, притом имеет максимально прозрачную методологию эксперимента (см. раздел 3).

3. МЕТОД

3.1. Описание набора данных

Объем общедоступных данных магнитно-резонансной томографии (МРТ) в формате `.nii` (представленных в виде трехмерных тензоров) является крайне ограниченным. Дополнительную сложность представляет мультиклассовый характер решаемой задачи. В связи с этим был сформирован агрегированный набор данных из открытых репозиториев, включающий: 96 снимков пациентов с синдромом дефицита внимания и гиперактивности (СДВГ) [7], 79 снимков пациентов с расстройством аутистического спектра (РАС) [8], 44 снимка пациентов с болезнью Альцгеймера [9], 40 снимков пациентов с болезнью Паркинсона [10], 82 снимков контрольной группы [11] [8] [7], а также 17 снимков пациентов с рассеянным склерозом, выделенных в качестве дополнительного тестового подмножества [12].

В связи с гетерогенной природой нейропсихиатрических заболеваний, сбор данных для класса расстройства аутистического спектра (РАС) сопряжен с рядом методологических трудностей. Предварительный разведочный анализ (exploratory data analysis) показал, что часть снимков РАС обладает высокой вариабельностью протоколов сканирования и потенциальным шумом в разметке, что приводило к размыванию границы принятия решений между РАС и контрольной группой на этапе обучения. Тем не менее, для сохранения клинической репрезентативности и оценки способности модели к тонкой дифференциальной диагностике, класс РАС был сохранен в итоговом наборе данных, состоящем из 358 снимков и 6 классов.

Набор данных содержит снимки как в T1-, так и в T2-взвешенных последовательностях. Значительная часть данных была получена в исходном (сыром) виде, тогда как остальные снимки уже прошли первичную предобработку (удаление черепной коробки, сегментация серого вещества, пространственное сглаживание и регистрация в единое координатное пространство).

3.2. Предобработка данных

После агрегации все исходные снимки прошли двухэтапную процедуру предобработки.

На первом этапе применялся стандартизированный конвейер обработки с использованием программного обеспечения FSL (FMRIB Software Library):

- Удаление черепной коробки (skull stripping) с помощью утилиты `fsl bet`.
- Сегментация и выделение серого вещества с использованием `fsl fast`.
- Пространственная регистрация МРТ-снимков в стандартное пространство MNI152 с применением `fsl flirt`.
- Пространственное сглаживание изображений с использованием `fsl math`.

На втором этапе к агрегированному набору данных был применен модифицированный итеративный алгоритм снижения размерности тензорных данных — многомерный анализ главных компонент (MPCA, Multilinear Principal Component Analysis).

3.3. Применение алгоритма MPCA

Алгоритм MPCA [13] является многомерным обобщением классического метода главных компонент (PCA[14]). Его ключевым преимуществом является возможность непосредственной работы с тензорами произвольной размерности без их предварительного развертывания в векторы. В контексте данной работы рассматриваются тензоры строго определенной размерности, что позволяет формализовать задачу с учетом специфики предметной области.

Формализация задачи:

- **Вход:** $\mathscr{X} \in \mathbb{R}^{N \times I_1 \times I_2 \times I_3}$ — исходный набор данных после первого этапа предобработки, где N — количество образцов, а I_1, I_2, I_3 — пространственные размерности тензора.
- **Выход:** $\mathscr{Y} \in \mathbb{R}^{N \times I_1 \times I_2 \times 3}$ — преобразованный набор данных после применения MPCA.

При этом преобразование описывается как $\mathscr{Y} = \mathscr{X} \times_4 U^{(4)T}$, где $U^{(4)T} \in \mathbb{R}^{3 \times I_3}$, а матрица $U^{(4)}$ находится путем решения задачи оптимизации:

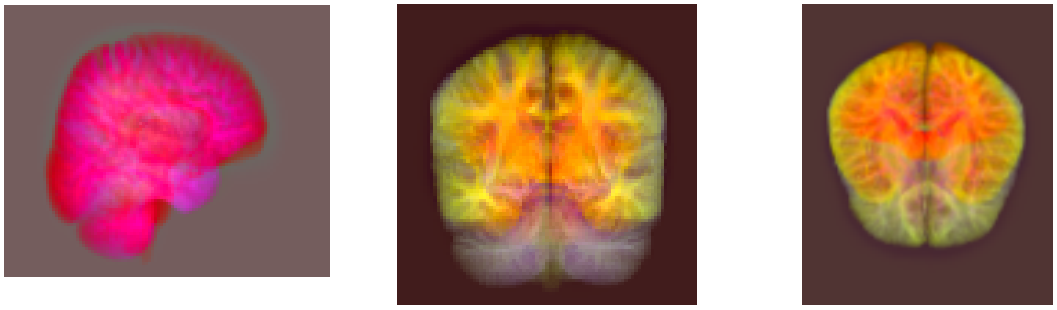
$$\arg\max_{U^{(4)}} \sum_{k=1}^{N} ||Y_k - \overline{Y}||_F^2. \tag{1}$$

Выбор размерности $\mathscr{Y} \in \mathbb{R}^{N \times I_1 \times I_2 \times 3}$ выходного тензора обосновывается необходимостью применения методов трансферного обучения (transfer learning). В условиях ограниченного объема данных обучение глубокой нейронной сети с нуля сопряжено с высоким риском переобучения. Оптимальным решением является использование предобученных сверточных нейронных сетей (CNN), извлекших общие признаки из крупномасштабных наборов данных, таких как ImageNet[15]. Поскольку изображения в ImageNet[15] представлены в формате RGB (3 канала), целевая размерность данных также должна быть приведена к 3 каналам.

С учетом анатомической специфики МРТ-снимков, имеющих три ортогональные плоскости (сагиттальную, фронтальную и аксиальную), применение алгоритма MPCA [13] позволяет сгенерировать следующие представления:

$$\mathscr{L}_{\text{sagittal}} \in \mathbb{R}^{N \times I_1 \times I_2 \times 3},$$
$$\mathscr{L}_{\text{frontal}} \in \mathbb{R}^{N \times I_1 \times 3 \times I_3},$$
$$\mathscr{L}_{\text{axial}} \in \mathbb{R}^{N \times 3 \times I_2 \times I_3}.$$

Таким образом, на входе алгоритма имеется N трехмерных МРТ-снимков размерности $I_1 \times I_2 \times I_3$, а на выходе формируется $3N$ двумерных изображений размерности $J_1 \times J_2 \times 3$



(а) Аксиальная **(б)** Фронтальная **(в)** Сагиттальная

Рис. 1. Пример работы алгоритма MPCA

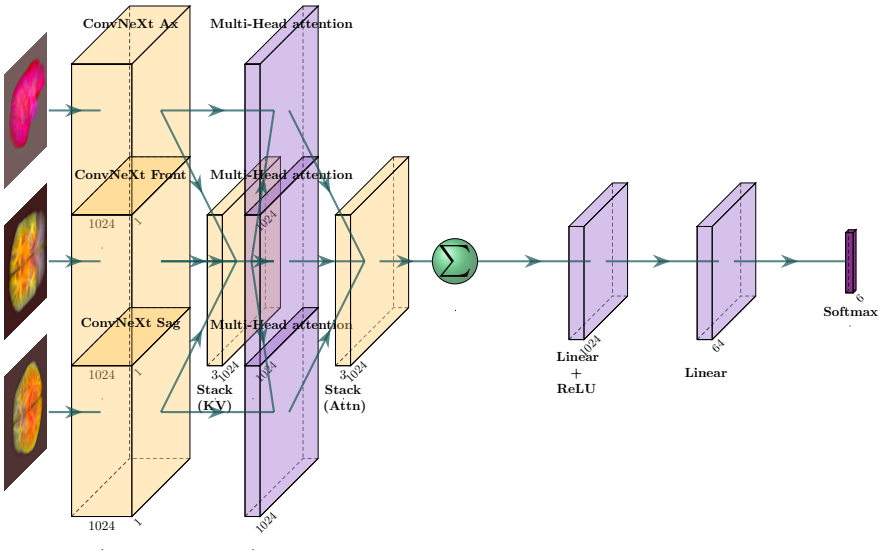


Рис. 2. Архитектура модели

(по N срезов для каждой из трех плоскостей), пригодных для обработки стандартными CNN-архитектурами.

На картинках 1 можно оценить результат работы алгоритма MPCA - проекции вдоль соотвествующих ортогональных осей.

3.4. Архитектура модели

На рисунке 2 представлено схематическое описание архитектуры.

Архитектура предлагаемой модели построена на следующих принципах. На вход нейронной сети подаются три изображения, соответствующие различным анатомическим плоскостям одного и того же магнитно-резонансного томографического (МРТ) исследования. Извлечение признаков осуществляется с помощью трех независимых потоков (branches), реализованных на базе архитектуры ConvNeXt-Tiny [16]. Каждый поток обрабатывает данные соответствующей плоскости, формируя на выходе плотный вектор признаков (dense feature vector), характеризующий данную проекцию. Для слияния информации между различными плоскостями применяется механизм многоголового

внимания (Multi-Head Attention) [17]. В рамках данного модуля в качестве запроса (Query, Q) выступает вектор признаков конкретной плоскости, тогда как в роли ключей (Key, K) и значений (Value, V) используется конкатенация векторов признаков всех трех плоскостей [17]. После проецирования исходных представлений в пространство внимания выполняется конкатенация. Результирующий агрегированный вектор признаков затем подается на вход блока классификации (classification head) для формирования итогового прогноза.

3.5. Алгоритм обучения

На этапе обучения данные были разбиты на 2 подвыборки: обучающая и тестовая в соотношении 0.8 и 0.2 соответственно. К обучающим данным на этапе обучения применялись техники аугментации из таблицы 1.

Табл. 1. Применяемые техники аугментации данных

Метод и параметры
RandomAffine
`degrees=(-7, 7), translate=(0.08, 0.08),`
`scale=(0.92, 1.10), shear=(-7, 7),`
`interpolation=BICUBIC, fill=0`
ElasticTransform
`alpha=120, sigma=8, interpolation=BICUBIC, fill=0`
RandomHorizontalFlip
`p=0.5`
RandomVerticalFlip
`p=0.15`
ColorJitter
`brightness=(0.7, 1.4), contrast=(0.75, 1.35),`
`saturation=0, hue=0`
GaussianNoise
`sigma=0.015`
GaussianBlur
`kernel_size=3, sigma=(0.4, 1.4)`

В качестве функции потерь выбрана взвешенный Focal Loss (weighted Focal Loss), в качестве оптимизатора выбран AdamW [18] (см. параметры в таблице 2).

Табл. 2. Параметры оптимизатора AdamW

Оптимизатор и параметры
AdamW
`weight_decay=1e-4`
Группы параметров:
clf_head
`lr=3e-4`
model_ax
`lr=1e-6, requires_grad=True`
model_sag
`lr=1e-6, requires_grad=True`
model_front
`lr=1e-6, requires_grad=True`

4. ЭКСПЕРИМЕНТЫ И РЕЗУЛЬТАТЫ

4.1. Подбор гиперпараметров

В связи с малым объемом выборки и высоким риском переобучения для получения несмещённой оценки обобщающей способности модели применялась вложенная стратифицированная 3-кратная кросс-валидация [19, 20]. Стратификация обеспечивала сохранение пропорций целевых классов в каждом разбиении [21]. Количество внешних фолдов было установлено равным трём вследствие ограниченного объёма доступных данных.

В качестве целевой метрики для подбора гиперпараметров и итоговой оценки модели был выбран **Macro F1-score** [22].

$$Precision_c = \frac{TP_c}{TP_c + FP_c} \quad Recall_c = \frac{TP_c}{TP_c + FN_c}$$

$$F_{1,c} = \frac{2Precision_c \cdot Recall_c}{Precision_c + Recall_c} \quad MacroF_1 = \frac{1}{C}\sum_{c=1}^{C} F_{1,c}$$

Выбор данной метрики обусловлен выраженным дисбалансом классов в агрегированном наборе данных (например, соотношение классов СДВГ и рассеянного склероза составляет 96:17).

Использование метрик *Micro F1* [22] или *Weighted F1* [22] в условиях столь значительного дисбаланса привело бы к доминированию мажоритарных классов в итоговой оценке: модель могла бы демонстрировать высокие агрегированные показатели за счет корректной классификации частых заболеваний, игнорируя при этом паттерны редких патологий. В клинической практике ложноотрицательный результат для любого из рассматриваемых заболеваний несет одинаково высокие риски для пациента. Метрика Macro F1[22], вычисляющая среднее значение F1-меры по всем классам без учета их размера, обеспечивает равнозначный вклад каждого заболевания в итоговую оценку и

принуждает алгоритм к формированию разделяющих границ для всех классов, включая миноритарные.

Поиск гиперпараметров (Inner Loop). Оптимизация гиперпараметров архитектуры (базовая модель ConvNeXt[16], размерность скрытого слоя, количество голов внимания, скорость обучения) осуществлялась с использованием байесовской оптимизации (алгоритм TPE, фреймворк Optuna[23]). Для оценки каждой комбинации гиперпараметров применялась 3-кратная стратифицированная кросс-валидация на обучающем подмножестве. В качестве целевой метрики оптимизации выступал Macro F1-score, усредненный по фолдам. Использование стратификации гарантировало сохранение пропорций классов в каждом фолде, что критически важно в условиях выраженного дисбаланса выборки.

Финальная оценка (Outer Loop). После определения оптимального набора гиперпараметров, финальная модель обучалась на объединенном обучающем и валидационном подмножествах (0.8 данных) и оценивалась на полностью изолированном тестовом подмножестве (0.2 данных), которое не участвовало ни в обучении, ни в процессе подбора гиперпараметров. Данный подход исключает утечку данных (data leakage) и обеспечивает несмещенную оценку обобщающей способности алгоритма.

В качестве функции потерь на всех этапах использовался взвешенный FocalLoss (weighted FocalLoss) [24] с коэффициентами, обратными частоте классов, что позволило нивелировать влияние дисбаланса на процесс оптимизации градиентным спуском.

4.2. Основные результаты классификации

Табл. 3. Результаты классификации на тестовой выборке (hold-out validation)

Метрика	Значение
Weighted FocalLoss	0.0012
Accuracy	0.9444
Macro F1	0.9592
Macro Recall	0.9607
Macro Precision	0.9666

Анализ матрицы ошибок обученной модели демонстрирует, что алгоритм допускает ошибки классификации исключительно при сопоставлении пациентов с РАС и представителей контрольной группы, в то время как остальные классы разделяются с высокой точностью. Данное эмпирическое наблюдение находится в полном согласии с фундаментальными проблемами нейровизуализационной диагностики РАС. В отличие от заболеваний с выраженными макроскопическими структурными изменениями, нейроанатомические и функциональные маркеры РАС носят распределенный характер. Как отмечается в недавнем систематическом обзоре и метаанализе ([25]), ключевым препятствием для бинарной классификации РАС и здоровых лиц является выраженная биологическая гетерогенность расстройства. Эта гетерогенность приводит к тому, что в пространстве признаков кластеры РАС и контрольной группы неизбежно пересекаются: часть индивидов с РАС демонстрирует нейровизуализационные паттерны, статистически неотличимые от нормы, что и обуславливает наблюдаемые ошибки классификации исключительно между этими двумя классами. Таким образом, зона неопределенности между группа-

ми отражает не недостаток предложенного алгоритма, а объективную биологическую вариабельность внутри спектра аутизма

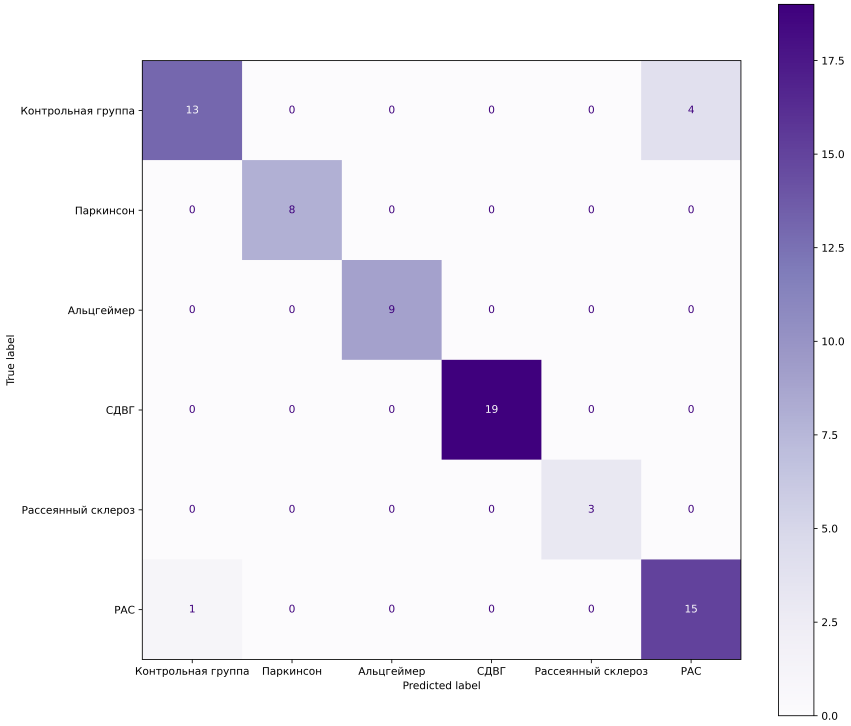


Рис. 3. Матрица ошибок на тестовой выборке

Способность модели безошибочно выделять сложные патологии (Alzheimer, Parkinson, Sclerosis) и при этом демонстрировать ожидаемую клиническую неопределенность (см. рис. 3) исключительно на границе контрольная группа - РАС, подтверждает, что алгоритм извлекает релевантные биомаркеры, а не опирается на случайные артефакты датасета. Это служит дополнительным свидетельством валидности предложенного подхода на основе MPCA и Multi-Head Attention.

4.3. Абляционное исследование

Вариант архитектуры	Accuracy	Macro Recall	Macro Precision	Macro F1
Single Branch (Эвристический срез)	0.8318 ± 0.0285	0.8365 ± 0.0225	0.8440 ± 0.0327	0.8157 ± 0.0296
Single Branch (MPCA)	0.8656 ± 0.0359	0.8714 ± 0.0272	0.8702 ± 0.0413	0.8437 ± 0.0342
Multi Branch (MPCA + Mean)	0.9108 ± 0.0269	0.9127 ± 0.0271	0.9280 ± 0.0245	0.8939 ± 0.0255
Multi Branch (MPCA + Cat)	0.9206 ± 0.0115	0.9203 ± 0.0122	0.9313 ± 0.0167	0.8995 ± 0.0162
Multi Branch (MPCA + MHA + Mean)	0.9053 ± 0.0279	0.9056 ± 0.0292	0.9170 ± 0.0315	0.8883 ± 0.0293
Multi Branch (MPCA + MHA + Cat)	$\mathbf{0.9223 \pm 0.0089}$	$\mathbf{0.9226 \pm 0.0090}$	$\mathbf{0.9359 \pm 0.0135}$	$\mathbf{0.9022 \pm 0.0125}$

Табл. 4. Результаты абляционного исследования

Для объективной оценки вклада тензорной декомпозиции MPCA в итоговое качество классификации, в качестве базового уровня (baseline) была разработана и протестирована эвристическая модель отбора наиболее информативных срезов (Top-3 Informative

Slices).

В отличие от тривиального подхода, при котором единственный центральный срез дублируется во все три канала (R=G=B), что приводит к нулевой межканальной дисперсии и вырождению первого сверточного слоя, предложенный базовый уровень формирует псевдо-RGB представление путем выбора трёх различных срезов по ортогональной плоскости. Критерием отбора выступала норма Фробениуса ковариационной матрицы центрированного среза:

$$\text{Score}(S_i) = ||C_i||_F, \quad C_i = \frac{1}{W-1}\tilde{S}_i\tilde{S}_i^T, \tag{2}$$

где $\tilde{S}_i$ — матрица среза с вычтенным средним значением. Данный критерий отбирает не просто срезы с максимальной интенсивностью сигнала, а срезы с наибольшей текстурной сложностью и структурной вариативностью, что максимизирует информационную емкость входного тензора для предобученной 2D-сети.

Сравнение результатов представлено в таблице 4. Переход от эвристического отбора локальных срезов (Top-3 Informative Slices) к глобальной тензорной проекции (MPCA) обеспечил прирост Macro F1 на $\sim 2.8\%$.

Последовательное усложнение архитектуры агрегации признаков позволило выявить оптимальную конфигурацию многоветвистой модели. Как следует из таблицы 4, простое усреднение выходов механизма внимания (MPCA + MHA + Mean) оказывается неэффективным: несмотря на использование адаптивного механизма взвешивания, итоговая производительность модели уступает базовому варианту с конкатенацией (MPCA + Cat), а дисперсия метрик возрастает почти вдвое, что свидетельствует о повышенной чувствительности архитектуры к разбиению на фолды. Преодолеть данное ограничение удалось за счёт отказа от усреднения в пользу конкатенации признаков, обработанных механизмом MHA. Итоговая конфигурация (MPCA + MHA + Cat) не только превосходит все предыдущие варианты по абсолютным значениям метрик, но и демонстрирует минимальный разброс результатов при кросс-валидации, что подтверждает её пригодность для решения задач дифференциальной диагностики, где критически важна воспроизводимость предсказаний.

5. ЗАКЛЮЧЕНИЕ

В рамках данного исследования предложен и экспериментально подтверждён новый подход к мультиклассовой классификации нейродегенеративных заболеваний по данным МРТ, объединяющий тензорную декомпозицию MPCA, многоветвистую сверточную нейросеть и механизм многоголового внимания.

Основная научная новизна работы заключается в следующем:

- Впервые для задачи классификации МРТ-снимков предложено использование алгоритма MPCA в качестве автоматизированного и детерминированного инструмента проекции трёхмерного тензора на три ортогональные анатомические плоскости с формированием псевдо-RGB представлений. В отличие от существующих подходов [2, 3, 4, 5, 6], в которых этап извлечения двумерных срезов либо не описан, либо выполнен эвристически, предложенный метод обеспечивает полную прозрачность и воспроизводимость предобработки без участия эксперта-разметчика.
- Предложена архитектура позднего слияния признаков на основе многоголового внимания, обеспечивающая адаптивное взвешивание информационных потоков

от различных анатомических проекций. Абляционное исследование показало, что данная конфигурация превосходит альтернативные стратегии агрегации (усреднение, простая конкатенация) как по абсолютным значениям метрик, так и по стабильности результатов при кросс-валидации.

- Продемонстрирована возможность применения предобученных 2D-моделей (transfer learning) к задаче анализа объёмных МРТ-данных в условиях крайне ограниченного объёма размеченной выборки (358 снимков, 6 классов) без необходимости обучения сети с нуля, что существенно снижает требования к вычислительным ресурсам.

Предложенный подход показал значительное увеличение качества классификации: метрика Macro F1 возросла с 0.8157 ± 0.0296 (эвристический отбор срезов) до 0.9022 ± 0.0125 (MPCA + MHA + Cat), а на изолированной тестовой выборке достигнуты значения Accuracy = 0.9444 и Macro F1 = 0.9592. При этом в отличие от работ [2, 4, 5], опирающихся на данные сомнительного происхождения (агрегаторы изображений из неструктурированных интернет-источников), настоящее исследование проведено на валидных объёмных МРТ-тензорах (.nii) из верифицированных открытых репозиториев, что исключает риск неконтролируемой утечки данных.

Характер допущенных моделью ошибок (исключительно на границе РАС — контрольная группа) согласуется с данными современной нейровизуализационной литературы [25] о биологической гетерогенности расстройств аутистического спектра и подтверждает, что алгоритм извлекает клинически релевантные биомаркеры, а не опирается на артефакты датасета.

Вместе с тем работа имеет ряд ограничений: дифференциация РАС и контрольной группы остаётся затруднённой вследствие объективной вариативности нейровизуализационных паттернов; вычислительная стоимость этапа MPCA-предобработки возрастает линейно с объёмом выборки. В качестве направлений дальнейшего развития предполагается масштабирование подхода на более крупные когорты, интеграция дополнительных модальностей (DTI, fMRI), а также исследование возможности замены MPCA на обучаемые тензорные проекции.

СПИСОК ЛИТЕРАТУРЫ

1. Mzoughi H., Njeh I., Wali A., Slima M. B., BenHamida A., Mhiri C., and Mahfoudhe K. B. Deep Multi-Scale 3D Convolutional Neural Network (CNN) for MRI Gliomas Brain Tumor Classification. URL: https://pubmed.ncbi.nlm.nih.gov/32440926/.
2. Amreen B. and Yung-Cheol B. A lightweight multi-path convolutional neural network architecture using optimal features selection for multiclass classfication of brain tumor using magnetic resonance images // Results in Engineering. 2025. Vol. 15.
3. Aqib A., Xinde L., Wali Khan M., Mohammad A., Faten Khalid K., and Samih M. M. Multi-class brain tumor MRI segmentation and classification using deep learning and machine learning approaches // Cancer Imaging. 2025. Vol. 18.
4. C. Kishor Kumar R., Pulakurthi Anaghaa R., Himaja J., Basem A., Mohammed S., Shadab A., and Abdullah S. A fine-tuned vision transformer based enhanced multi-class brain tumor classification using MRI scan imagery // Frontiers in Oncology. 2024. Vol. 23.
5. Deependra R., Prashant J., Varun T., and Ahmed A. E. Multi-class classification of brain tumour magnetic resonance images using multi-branch network with inception block and five-fold cross validation deep learning framework // Biomedical Signal Processing and Control. 2024. Vol. 22.
6. K. J. and Shirley S. Multiclass convolutional neural network based classification for the diagnosis of brain MRI images // Biomedical Signal Processing and Control. 2023. Vol. 18.

7. The Neuro Bureau ADHD-200 Preprocessed repository. 2017. URL: http://preprocessed-connectomes-project.org/adhd200/.
8. Autism Brain Imaging Data Exchange I ABIDE I. 2012. URL: https://fcon_1000.projects.nitrc.org/indi/abide/abide_I.html.
9. OASIS-3: Longitudinal Neuroimaging, Clinical, and Cognitive Dataset for Normal Aging and Alzheimer Disease. 2019. URL: https://sites.wustl.edu/oasisbrains/home/oasis-3/.
10. Parkinson's Precision Medicine Initiative. URL: https://www.ppmi-info.org/access-data-specimens/download-data.
11. Information eXtraction from Images. URL: https://brain-development.org/ixi-dataset/.
12. The 2015 Longitudinal MS Lesion Segmentation Challenge. 2015. URL: https://iacl.ece.jhu.edu/index.php/MSChallenge.
13. Haiping L., K.N. P., and A.N. V. MPCA: Multilinear Principal Component Analysis of Tensor Objects // IEEE Transactions on Neural Networks. 2006. Vol. 43.
14. Maćkiewicz A. and Ratajczak W. Principal components analysis (PCA). URL: https://www.sciencedirect.com/science/article/abs/pii/009830049390090R.
15. Russakovsky O., Deng J., Su H., Krause J., Satheesh S., Ma S., Huang Z., Karpathy A., Khosla A., Bernstein M., Berg A. C., and Fei-Fei L. ImageNet Large Scale Visual Recognition Challenge. 2015. URL: https://arxiv.org/abs/1409.0575.
16. Liu Z., Mao H., Wu C.-Y., Feichtenhofer C., Darrell T., and Xie S. A ConvNet for the 2020s. 2022. URL: https://arxiv.org/abs/2201.03545.
17. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser L., and Polosukhin I. Attention Is All You Need. 2023. URL: https://arxiv.org/abs/1706.03762.
18. Loshchilov I. and Hutter F. Decoupled Weight Decay Regularization. 2019. URL: https://arxiv.org/abs/1711.05101.
19. Cawley G. C. and Talbot N. L. C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. 2010. URL: https://www.researchgate.net/publication/220320908_On_Over-fitting_in_Model_Selection_and_Subsequent_Selection_Bias_in_Performance_Evaluation.
20. Varma S. and Simon R. Bias in error estimation when using cross-validation for model selection. 2006. URL: https://pubmed.ncbi.nlm.nih.gov/16504092/.
21. Varma S. and Simon R. A study of cross-validation and bootstrap for accuracy estimation and model selection. 2006. URL: https://pubmed.ncbi.nlm.nih.gov/16504092/.
22. Sokolova M. and Lapalme G. A systematic analysis of performance measures for classification tasks. 2009. URL: https://www.sciencedirect.com/science/article/pii/S0306457309000259?via%3Dihub.
23. Optuna framework. URL: https://optuna.readthedocs.io/en/stable/.
24. Lin T.-Y., Goyal P., Girshick R., He K., and Dollár P. Focal Loss for Dense Object Detection. 2018. URL: https://arxiv.org/abs/1708.02002.
25. Sjir J. C. S., Jesper P., Albert P. A., and Zinger S. The diagnosis of ASD with MRI: a systematic review and meta-analysis // Translational Psychiatry. 2024. Vol. 11.

Берлет Максим Валерьевич, студент 4 курса прикладной математики и информатики, СПбГЭТУ «ЛЭТИ», ✉ berletmaximq@gmail.com

Филатов Антон Юрьевич, кандидат технических наук, доцент кафедры Кафедра математического обеспечения и применения ЭВМ СПбГЭТУ «ЛЭТИ», aifilatov@etu.ru

Research article
№ –: 1–14
UDC: 999.999
http://cte.eltech.ru
doi:10.32603/2071-2340-2026-4-XXX-XXX

MPCA-Attention: Multi-Branch CNN for MRI Classification via Orthogonal Projections

Berlet M. V.[1] ✉ berletmaximq@gmail.com, https://orcid.org/0009-0003-0513-3806
Filatov A. Y.[1] aifilatov@etu.ru, https://orcid.org/0000-0003-4298-8523

[1]Saint Petersburg State Electrotechnical University "LETI", Professora Popova ul. 5, St. Petersburg, 197022, Russian Federation

Abstract

Timely diagnosis of diseases identifiable via magnetic resonance imaging (MRI) is crucial for selecting the optimal treatment strategy. The automation of this process is driven by the need to reduce the workload on clinical specialists. The objective of this study is to develop a patient classification algorithm based on MRI scans that remains effective under conditions of limited computational resources and small volumes of annotated data. We propose an approach based on the decomposition of a 3D MRI tensor along orthogonal planes using Multilinear Principal Component Analysis (MPCA), feature extraction via a multi-branch convolutional neural network, and subsequent late fusion of features employing a multi-head attention mechanism to adaptively weight the information streams. The evaluation was conducted on a dataset of 358 patient scans using 5-fold cross-validation. Accuracy and Macro F1-score were employed as the evaluation metrics. On hold-out validation, the model demonstrated an Accuracy of 0.9444 and a Macro F1-score of 0.9592

Keywords: *Multilinear Principal Component Analysis; Multi-branch Convolutional Neural Network; Multi-Head Attention; Late Feature Fusion; Classification; MRI;*

Citation: M. V. Berlet and A. Y. Filatov, "MPCA-Attention: Multi-Branch CNN for MRI Classification via Orthogonal Projections," Computer Tools in Education, no. –, pp. 1–14, 2026, doi:10.32603/2071-2340-2026-4-XXX-XXX.

Berlet Maxim, 4 year student of applied math and computer science, SPBETU «LETI», ✉ berletmaximq@gmail.com

Filatov Anton, PhD in Engineering, Associate Professor of the Department of Software Engineering and Computer Applications, aifilatov@etu.ru